Programa AWS Big Data Analytics Specialist

Informe Arquitectura Final AWS

Integrantes:

Anthony Steve Brian Manosalva López Julian Castiblanco P Jennyfer Nereida Combariza Vanegas Isel Paola Santos Rojas

Junio 2020

Introducción

Este proyecto constituye el informe final del curso AWS Big Data Analytics Specialist.

Comprender las emociones de las personas cada día se convierte en una de las herramientas más esenciales para las empresas, ya que les permite escuchar atentamente a sus clientes y adaptar sus productos y/o servicios para satisfacer sus necesidades.

En este breve proyecto vamos a explicar como hacer una arquitectura serverless para realizar análisis de sentimientos de tweets relacionados con el covid en Perú.

Para esa arquitectura serverless usaremos los siguientes servicios de AWS:

- 1. Kinesis Firehose: servicio de AWs que permite el procesar datos en tiempo real.
- 2. Lambda: servicio de AWS que ejecuta cómputo a demanda.
- 3. Comprehend: servicio de procesamiento de lenguaje natural.
- 4. Lambda: servicio de AWS que ejecuta cómputo a demanda.
- 5. Elastic Search: servicio de AWS facilita la implementación, la protección y la ejecución de Elasticsearch a escala de manera rentable
- Kibana. Ventana al Elastic Stack. Kibana es una interfaz de usuario gratuita y abierta que te permite visualizar los datos de Elasticsearch


Para este análisis de sentimientos recopilamos los tweets con Kinesis Firehose, los procesamos con comprehend y visualizamos utilizando Elastic Search- Kibana.

1. Objetivo

Construir una arquitectura serverless que permita la visualización de análisis de sentimientos de tweets en tiempo real.

2. Arquitectura propuesta

Arquitectura propuesta End to End



3. Alcance

El presente documento describe los lineamientos llevados a cabo para la generación de la arquitectura propuesta desde la extracción de los tweets hasta la visualización de los resultados obtenidos del análisis de sentimientos.


4. Configuraciones generales

A continuación se listan los servicios que se usaron en el proceso de la generación de la arquitectura:

4.1. Configuración de EC2

Se crea una máquina EC2 que se encargará de ejecutar un código Python para conectarse con la cuenta de desarrollo de twitter y de esa manera extraer información acerca del covid en Lima Perú, con filtro de idioma en español.






4.2. Conexión a EC2 por SSH a través de Putty

Objetivo: Cargar el código de python e instalar las librerías necesarias para una conexión exitosa.


Paso 1: Se descarga el archivo pem, donde viene la key privada.



 Paso 2: Se abre la herramienta "putty generator" para convertir el archivo pem en ppk que es válido para la conexión desde putty.




Paso 3: Se hace conexión a través de putty.




- Paso 4: Se modificó el py, para que se conecte a firehose el cual va a recibir la información en formato json, codificado a 64 bits el mensaje.
- Paso 5: Se ejecuta la función de extracción de tweets.



4.3. Configuración del servicio de Firehose



4.4. Configuración del servicio de Lambda, S3 y Elasticsearch



4.5. Configuración del servicio Elasticsearch

Amazon Elasticsearch Service destination

Domain
elasticawsgrupo1 C*

Index
tweet

Index rotation
Every day

Retry duration
300 seconds


Buffer conditions
5 MiB or 60 seconds

Settings


CloudWatch error logging
Enabled

4.6. Creación de la función Lambda


Se creó una función lambda que se encarga de utilizar el servicio de comprenhed, para analizar los tweets.




Se modificó la configuración de la función para que durara más tiempo y pueda utilizar más memoria en el procesamiento:




4.7. Creación del elasticSearch





Transform source records with AWS Lambda

To return records from AWS Lambda to Kinesis Data Firehose after transformation, the Lambda function you invoke must be compliant with the required record transformation output model. Learn more 🔀




Timeout 3 seconds Convert record format Data in Apache Parquet or Apache ORC format is typically more efficient to query than JSON. Kinesis Data Firehose can convert your JSON-formatted source records using a schema from a table defined in AWS Glue 🕜. For records that aren't in JSON format, create a Lambda function that converts them to JSON in the Transform source records with AWS Lambda section above. Learn more Record format conversion Disabled Enabled If record format conversion is enabled, Kinesis Data Firehose can deliver data to Amazon S3 only. Record format conversion will be configured using the OpenX JSON SerDe. For other options use the AWS CLI Cancel Previous Next Select a destination Learn more 🗷 Destination ○ Amazon S3 mazon S3 is an easy-to-use object storage, with a simple web service interface to store and retrieve any amount of data from anywhere on the web. Amazon Redshift Amazon Redshift is a fast, fully managed, petabyte-scale data warehouse that makes it simple and cost effective to analyze all your data using your existing business intelligence tools Amazon Elasticsearch Service Elasticsearch is an open-source search and analytics engine for use cases such as log analytics, real-time application monitoring, and click stream Splunk Splunk is an operational intelligence tool for analyzing machine-generated data in real-time delivery stream for VPC connectivity. Learn more C elasticawsgrupo1 Create new 🖸 View elasticawsgrupo1 in Amazon Elasticsearch Service
☑ Index A new index will be created if the the specified index name does not exist. Index rotation Select how often to rotate the Elasticsearch index. Kinesis Data Firehose appends a corresponding timestamp to the index and rotates it. Туре A new type will be created if the specified type name does not exist. Retry duration Select how long a failed index request should be retried. Failed documents are delivered to the backup S3 bucket. 300 seconds Enter a retry duration from 0 - 7200 seconds


longer in the Advanced settings section of your Lambda configuration.

Go to Lambda configuration 🖸

S3 backup To prevent against data loss, Kinesis Data Firehose can back up records to your S3 bucket while delivering it to your Elasticsearch cluster. Learn more 🔀 Backup mode Failed records only All records Backup S3 bucket Create new grupo1-bucket View grupo1-bucket in S3 console ☑ Backup S3 bucket prefix - optional tweet/ Kinesis Data Firehose automatically appends the "YYYY/MM/dd/HH/" UTC prefix to delivered S3 files. You can also specify an extra prefix in front of the time format and add "/" to the end to have it appear as a folder in the S3 console. Previous Next Cancel Elasticsearch buffer conditions Kinesis Data Firehose buffers incoming records before delivering them to your Elasticsearch domain. Data delivery will be triggered when either of these conditions is satisfied. Learn more 🔀 Buffer size MiB Enter a buffer size between 1-100 MiB 60 seconds Enter a buffer interval between 60-900 seconds S3 compression and encryption s before delivering them to your S3 bucket. Compressed records can also be encrypted in the S3 bucket using a Kinesis Data Firehose can compress rec KMS master key. **Learn more** S3 compression Disabled O GZIP Snappy O Zip Hadoop-Compatible Snappy S3 encryption Disabled Enabled **Error logging** Kinesis Data Firehose can log record delivery errors to CloudWatch Logs. If enabled, a CloudWatch log group and corresponding log streams are created on your behalf. Learn more [3] Error logging Disabled Enabled Tags - optional You can add tags to organize your AWS resources, track costs, and control access. Learn more Key Value - optional Enter key Enter value Remove tag



Se modificaron los permisos para acceder al Kibana desde cualquier lugar público



4.8. Ejecución del proceso de adquisición de tweets




Se valida que se haya creado el índice del elasticsearch




4.9. Visualización de adquisición de tweets


Una vez que se tiene información en el motor de búsqueda, accedemos a la URL de kibana y podemos configurar el índice de búsquedas.



A continuación, en el ícono de discover, podemos validar los datos disponibles para la creación de las gráficas.




Seleccionamos nueva gráfica de barras




Seleccionamos el set de datos que queremos analizar


New Vertical Bar / Choose a source




En el eje Y se deja que cuente cuantos registros hay por tipo de respuesta sentimental



A continuación le damos clic en el botón add bucket





De manera similar se pueden replicar los pasos para realizar un gráfico de tipo pie.

